

BULUT BİLİŞİM DERSİ

Proje 3 – Makine Öğrenmesi

Amazon SageMaker ile Bulutta Model Eğitim, Dağıtım ve Tahmin

Iris Çiçeği Tür Tahmini (RandomForest)

Hazırlayan: Yusuf Tanrıverdi

Ders: 3522 Bulut Bilişim

Proje deposu (tüm projeler): <https://github.com/ysftrv/bulut-bilisim-projeleri>

Bu projenin klasörü: <https://github.com/ysftrv/bulut-bilisim-projeleri/tree/main/proje-ml>

Video Linki = <https://youtu.be/xYyBbShfueE>

İçindekiler

İçindekiler.....	
1. Amaç ve Kapsam.....	
2. Kullanılan Teknolojiler	
3. Sistem Mimarisi ve Akış	
4. Yapılan Adımlar	
5. Kod ve Açıklamaları	
5.1. Model Eğitimi (train.py)	
5.2. Çıkarım Betiği (inference.py)	
5.3. Model Dağıtım (deploy.py).....	
5.4. Tahmin Alma (predict.py).....	
6. Çıktılar ve Sonuçlar	
7. Karşılanan Üç Çıktı	
8. Güvenlik.....	
9. Karşılaşılan Zorluklar ve Öğrenilenler.....	
10. Sonuç.....	

1. Amaç ve Kapsam

Bu projenin amacı, bir bulut platformu (Amazon Web Services) üzerinde Python kullanarak uçtan uca bir makine öğrenmesi çalışması gerçekleştirmektir. Çalışmada küçük ve temiz bir veri seti olan Iris çiçeği veri seti kullanılmış; böylece veri temizleme yükü en aza indirilip bulut tarafındaki eğitim ve dağıtım adımlarına odaklanılmıştır.

Proje kapsamında ulaşılmak istenen hedeflenen üç çıktı şunlardır:

1. Makine öğrenmesi modeli geliştirme.
2. Bulut üzerinde model eğitme ve model dağıtım (deployment).
3. Veriden bilgi çıkarma ve tahminlerde bulunma.

Çalışma bilinçli olarak sade tutulmuş, amacı bulut tabanlı makine öğrenmesi sürecinin temel başlıklarını (eğitim, dağıtım, tahmin) uygulamalı olarak öğrenmektir.

2. Kullanılan Teknolojiler

Projede kullanılan başlıca teknolojiler ve görevleri aşağıdaki tabloda özetlenmiştir.

Teknoloji	Görevi / Açıklaması
Python	Ana programlama dili.
scikit-learn 1.2.2	Makine öğrenmesi modelinin (RandomForest) geliştirilmesi.
numpy (<2)	Sayısal işlemler; scikit-learn ile uyum için sürüm sabitlendi.
joblib	Eğitilen modelin dosyaya kaydedilmesi (model.joblib).
Amazon SageMaker	Bulutta Jupyter not defteri ortamı, model eğitimi ve endpoint dağıtım.
SageMaker Python SDK	Modeli paketleyip endpoint olarak dağıtmak ve tahmin almak.
AWS S3	Model dosyasının (model.tar.gz) bulutta saklanması.
Amazon Linux / JupyterLab	Notebook Instance üzerinde çalışan hazır geliştirme ortamı.
AWS Bölgesi	us-east-1 (N. Virginia).

3. Sistem Mimarisi ve Akış

Çalışma üç temel adımdan oluşan basit bir akışa sahiptir. Her adım, projenin hedeflediği çıktılarından biriyle doğrudan eşleşmektedir:

4. Eğitim: SageMaker Notebook içinde Iris verisiyle bir RandomForest modeli eğitilir. Notebook bulutta çalıştığı için bu adım bulutta eğitimi temsil eder.
5. Dağıtım: Eğitilen model paketlenip Amazon S3'e yüklenir ve bir SageMaker endpoint'i (iris-endpoint) olarak dağıtılır. Bu, bulutta model dağıtımıdır.
6. Tahmin: Açılan endpoint'e yeni çiçek ölçüleri gönderilir ve model tür tahmini döndürür. Bu, veriden bilgi çıkarma ve tahmindir.

Akış şu şekilde özetlenebilir: Iris verisi → [Eğit: RandomForest] → [Dağıt: SageMaker Endpoint] → [Tahmin: tür sonucu].

4. Yapılan Adımlar

7. AWS Konsolu üzerinden us-east-1 bölgesinde Amazon SageMaker hizmeti açıldı.
8. "iris-ml-notebook" adında, ml.t3.medium tipinde bir Notebook Instance oluşturuldu ve gerekli IAM rolü tanımlandı.
9. JupyterLab açılarak conda_python3 çekirdeğinde yeni bir not defteri oluşturuldu.
10. scikit-learn ve numpy sürümleri (1.2.2 ve <2) sabitlenerek RandomForest modeli eğitildi ve doğruluk ölçüldü.
11. Model joblib ile kaydedildi, ardından SageMaker SDK ile paketlenip endpoint olarak dağıtıldı.
12. Endpoint'e örnek veriler gönderilerek tahminler alındı.
13. Maliyet kontrolü için endpoint silindi ve notebook durduruldu.
14. Tüm kodlar GitHub deposuna yüklendi.

5. Kod ve Açıklamaları

5.1. Model Eğitimi (train.py)

Aşağıdaki kod Iris verisini yükler, veriyi eğitim ve test olarak ayırır, RandomForest modelini eğitir, doğruluk değerini yazdırır ve modeli model.joblib dosyasına kaydeder.

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score
import joblib

iris = load_iris()
X, y = iris.data, iris.target
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

acc = accuracy_score(y_test, model.predict(X_test))
print("Test doğrulugu (accuracy):", acc)

joblib.dump(model, "model.joblib")
```

5.2. Çıkarım Betiği (inference.py)

Bu betik, endpoint'in modeli nasıl yükleyeceğini ve gelen JSON verisini nasıl işleyip tahmin döndüreceğini tanımlar. Dört fonksiyon sırasıyla: modeli yükleme, girdiyi okuma, tahmin üretme ve çıktıyı biçimlendirme görevlerini üstlenir.

```
import os, json
import joblib
```

```

import numpy as np

def model_fn(model_dir):
    return joblib.load(os.path.join(model_dir, "model.joblib"))

def input_fn(request_body, content_type):
    if content_type == "application/json":
        data = json.loads(request_body)
        return np.array(data["inputs"])
    raise ValueError("Desteklenmeyen content type: " + content_type)

def predict_fn(input_data, model):
    return model.predict(input_data)

def output_fn(prediction, accept):
    return json.dumps({"predictions": prediction.tolist()})

```

5.3. Model Dağıtımı (deploy.py)

Bu kod modeli model.tar.gz olarak paketler, Amazon S3'e yükler ve SKLearnModel sınıfı ile iris-endpoint adında bir endpoint açar. instance_type olarak maliyeti düşük ml.t2.medium seçilmiştir.

```

import tarfile, sagemaker
from sagemaker.sklearn.model import SKLearnModel

with tarfile.open("model.tar.gz", "w:gz") as tar:
    tar.add("model.joblib")

sess = sagemaker.Session()
role = sagemaker.get_execution_role()
model_data = sess.upload_data("model.tar.gz", key_prefix="iris-model")

sk_model = SKLearnModel(
    model_data=model_data, role=role, entry_point="inference.py",
    framework_version="1.2-1", py_version="py3")

predictor = sk_model.deploy(
    initial_instance_count=1, instance_type="ml.t2.medium",
    endpoint_name="iris-endpoint")

```

5.4. Tahmin Alma (predict.py)

Bu kod endpoint'e üç örnek çiçeğin ölçülerini gönderir ve dönen sayısal tahminleri tür isimlerine (setosa, versicolor, virginica) çevirir.

```

from sagemaker.predictor import Predictor
from sagemaker.serializers import JSONSerializer
from sagemaker.deserializers import JSONDeserializer

predictor = Predictor(
    endpoint_name="iris-endpoint",
    serializer=JSONSerializer(),
    deserializer=JSONDeserializer())

tur_isimleri = ["setosa", "versicolor", "virginica"]
yeni_veriler = {"inputs": [[5.1, 3.5, 1.4, 0.2],

```

```
[6.7,3.1,4.7,1.5],  
[6.3,3.3,6.0,2.5]]}
```

```
sonuc = predictor.predict(yeni_veriler)  
for veri, t in zip(yeni_veriler["inputs"], sonuc["predictions"]):  
    print(veri, "->", tur_isimleri[t])
```

6. Çıktılar ve Sonuçlar

Model eğitildiğinde test doğruluğu (accuracy) 1.0 (yüzde 100) olarak ölçülmüştür. Iris kolay ayırt edilebilen bir veri seti olduğu için bu yüksek değer beklenen bir sonuçtur.

Model başarıyla dağıtılmış ve “iris-endpoint” adında çalışan bir endpoint oluşmuştur. Endpoint'e gönderilen üç örnek için alınan tahminler aşağıdaki gibidir:

```
Olculer [5.1, 3.5, 1.4, 0.2] -> Tahmin: setosa  
Olculer [6.7, 3.1, 4.7, 1.5] -> Tahmin: versicolor  
Olculer [6.3, 3.3, 6.0, 2.5] -> Tahmin: virginica
```

Üç örnek de doğru sınıflandırılmış; böylece modelin yeni veriden anlamlı tahminler ürettiği gösterilmiştir.

7. Karşılanan Üç Çıktı

Hocanın istediği üç çıktının bu projede nasıl karşılandığı aşağıda eşleştirilmiştir.

- Çıktı 1 – Model geliştirme: Python ve scikit-learn ile bir RandomForest sınıflandırma modeli geliştirildi ve test doğruluğu 1.0 ölçüldü.
- Çıktı 2 – Bulutta eğitim ve dağıtım: Model, bulutta çalışan SageMaker Notebook içinde eğitildi ve bir SageMaker endpoint'i (iris-endpoint) olarak dağıtıldı.
- Çıktı 3 – Veriden bilgi çıkarma ve tahmin: Endpoint'e gönderilen yeni örnekler için doğru tür tahminleri alındı.

8. Güvenlik

- AWS erişim anahtarları koda yazılmadı; SageMaker'ın çalıştırma rolü (IAM role) üzerinden güvenli bağlantı kuruldu.
- GitHub deposunda .gitignore ile *.pem, *.key, *.crt gibi gizli dosyaların yüklenmesi engellendi; her commit öncesi git status ile kontrol yapıldı.
- Maliyet güvenliği için AWS Budgets üzerinde harcama alarmı tanımlı tutuldu ve kaynaklar iş bittikten sonra kapatıldı.

9. Karşılaşılan Zorluklar ve Öğrenilenler

- SageMaker konsolünün arayüzü güncellenmişti; “Notebook instances” seçeneği “Applications and IDEs” başlığı altına taşınmıştı. Doğru menü bulunarak çözüldü.
- Çalışma ortamında scikit-learn hazır gelmiyordu; %pip ile kuruldu. Ayrıca scikit-learn 1.2.2 ile numpy 2 arasında uyumsuzluk çıktı, numpy sürümü <2 olarak sabitlenerek giderildi.

- Modelin eğitildiği scikit-learn sürümü ile dağıtım kutusunun sürümünün aynı (1.2) olması gerektiği öğrenildi; aksi halde dağıtımda uyumsuzluk hatası oluşuyor.
- SageMaker endpoint'inin açık kaldıkça saatlik ücret işlediği, bu yüzden tahmin alındıktan hemen sonra silinmesi gerektiği öğrenildi.

10. Sonuç

Bu projede, Iris veri seti kullanılarak bulut üzerinde uçtan uca bir makine öğrenmesi süreci gerçekleştirilmiştir. Model geliştirme, bulutta eğitim ve dağıtım, ve yeni veriden tahmin üretme adımlarının hepsi Amazon SageMaker üzerinde uygulanmış; böylece projenin üç çıktısı da karşılanmıştır. Çalışma sade tutulmuş, bulut tabanlı makine öğrenmesinin temel adımları uygulamalı olarak öğrenilmiştir.